

# Formalne metode u softverskom inženjerstvu

## Laboratorijska vježba – Optimizacioni problemi

### 0-1 Knapsack optimizacioni problem

Neka važi:

- $n \in \mathbb{N}$  (broj objekata),
- $v_1, v_2, \dots, v_n \in \mathbb{R}^{\geq 0}$  (vrijednosti),
- $w_1, w_2, \dots, w_n \in \mathbb{R}^{\geq 0}$  (težine) i
- $C \in \mathbb{R}^{\geq 0}$  (kapacitet).

0-1 Knapsack optimizacioni problem je:

$$\begin{aligned} & \underset{c_1, c_2, \dots, c_n}{\text{maximize}} \quad \sum_{i=1}^n c_i v_i \\ & \text{subject to} \quad c_1, c_2, \dots, c_n \in \{0, 1\} \wedge \sum_{i=1}^n c_i w_i \leq C. \end{aligned}$$

$c_1, c_2, \dots, c_n$  možemo nazvati koeficijentima uključenja objekata.

Maksimalna ostvariva vrijednost, za fiksne vrijednosti i težine, se može formulisati kao rekurzivna funkcija,

$$K(n, C) = \begin{cases} 0 & \text{if } n = 0 \text{ or } C = 0 \\ K(n - 1, C) & \text{if } w_n > C \\ \max(v_n + K(n - 1, C - w_n), K(n - 1, C)) & \text{inače} \end{cases}.$$

Funkcija nam daje maksimalnu vrijednost koju možemo ostvariti sa svih  $n$  objekata i kapacitetom  $C$  kao maksimum sljedećeg:

- Ako ne uključujemo  $n$ -ti objekat - maksimalne vrijednosti koju možemo ostvariti sa  $n - 1$  preostalih objekata.
- Ako uključujemo  $n$ -ti objekat - zbraja vrijednosti  $n$ -tog objekta i maksimalne vrijednosti koja se može ostvariti sa  $n - 1$  preostalih objekata.

```
In [2]: def knapsack(vs, ws, C):
    def k(i, c):
        if 0 in (i, c):
            return 0
        elif ws[i-1] > c:
            return k(i-1, c)
```

```

    else:
        return max(k(i-1, c), k(i-1, c-ws[i-1]) + vs[i-1])
    return k(len(vs), C)

```

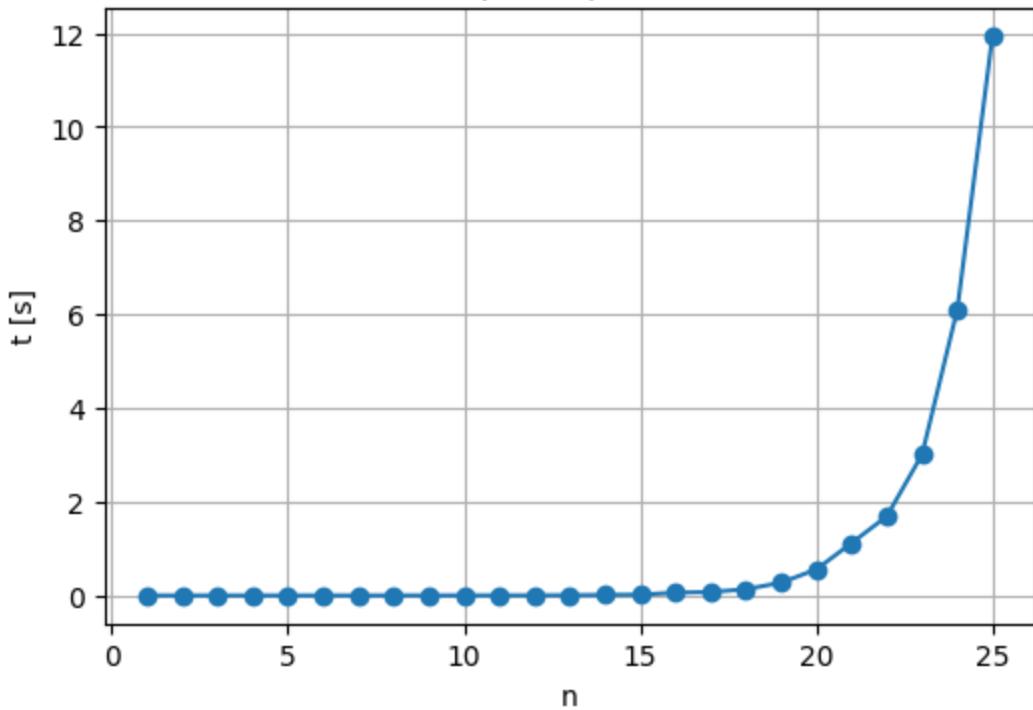
Izmjerićemo vrijeme izvršavanja u zavisnosti od broja objekata, kao veličine ulaza, u najgorem slučaju.

```
In [3]: import time
ns = range(1, 26)
ts = []
print('      n |      t')
for n in ns:
    vs = [1 for _ in range(n)]
    ws = [1 for _ in range(n)]
    C = sum(ws) # worst case
    t0 = time.time()
    knapsack(vs, ws, C)
    ts.append(time.time() - t0)
    print(f'{n:10d} {ts[-1]*1000:6.0f}ms')

# Plot
from matplotlib import pyplot as plt
plt.figure(figsize=(6, 4))
plt.plot(ns, ts, 'o-')
plt.xlabel('n')
plt.ylabel('t [s]')
plt.title('Knapsack problem')
plt.grid()
plt.show()
```

n	t
1	0ms
2	0ms
3	0ms
4	0ms
5	0ms
6	0ms
7	0ms
8	0ms
9	0ms
10	1ms
11	1ms
12	2ms
13	5ms
14	10ms
15	17ms
16	60ms
17	73ms
18	133ms
19	272ms
20	556ms
21	1119ms
22	1689ms
23	3008ms
24	6102ms
25	11951ms

Knapsack problem



## 0-1 Knapsack algoritam optimizovan tehnikom dinamičkog programiranja

Realizovati ćemo Python algoritam za pronalaženje maksimalne ostvarive vrijednosti, za 0-1 Knapsack problem, koji je optimizovan upotrebom tehnika dinamičkog programiranja.

Ponovimo rekurzivnu formulu za izračunavanje maksimalne ukupne vrijednosti:

$$K(n, C) = \begin{cases} 0 & \text{if } n = 0 \text{ or } C = 0 \\ K(n - 1, C) & \text{if } w_n > C \\ \max(v_n + K(n - 1, C - w_n), K(n - 1, C)) & \text{inače} \end{cases}.$$

Iz formule uočavamo da bismo mogli ubrzati izračunavanje za  $K(n, C)$  ukoliko već imamo izračunato  $K(n - 1, C)$  i  $K(n - 1, C - w_n)$ . Ideja se onda svodi na to da unaprijed izračunamo maksimalne ukupne vrijednosti kolekcija za prvih  $1, 2, 3, \dots$  objekata, za sve vrijednosti kapaciteta od  $C$  do 0. Onda će važiti da uvjek imamo već izračunato  $K(i - 1, c)$  i  $K(i - 1, C - w_i)$ , te da nije potrebno vršiti rekurzivni poziv.

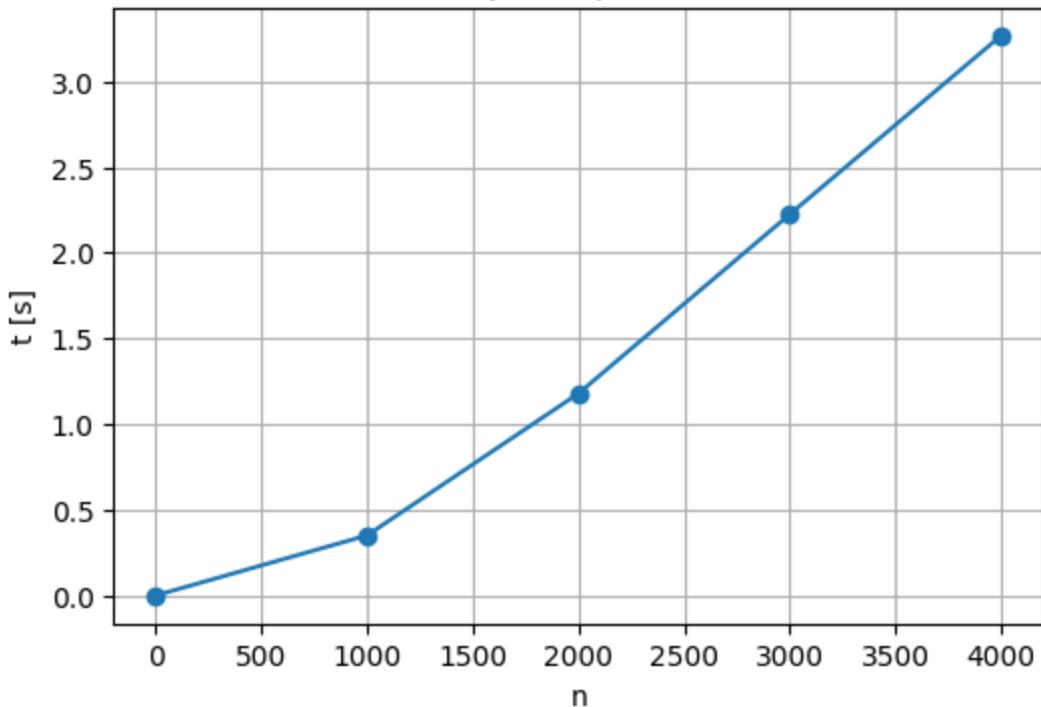
```
In [4]: def knapsack_dp(vs, ws, C):
    k = [0] * (C+1)
    for i in range(0, len(vs)): # Na početku i-te iteracije k je [K(i,0), K(i,1), ...
        for c in range(C, 0, -1):
            if ws[i] > c:
                continue
            k[c] = max(k[c], k[c-ws[i]] + vs[i]) # k[c] postaje K(i+1,c)
    return k[C] # K(n, C)
```

```
In [6]: import time
ns = range(1, 5000, 1000)
ts = []
print('n | t')
for n in ns:
    vs = [1 for _ in range(n)]
    ws = [1 for _ in range(n)]
    C = sum(ws) # worst case
    t0 = time.time()
    knapsack_dp(vs, ws, C)
    ts.append(time.time() - t0)
    print(f'{n:10d} {ts[-1]*1000:6.0f}ms')

# Plot
from matplotlib import pyplot as plt
plt.figure(figsize=(6, 4))
plt.plot(ns, ts, 'o-')
plt.xlabel('n')
plt.ylabel('t [s]')
plt.title('Knapsack problem')
plt.grid()
plt.show()
```

n	t
1	0ms
1001	351ms
2001	1179ms
3001	2225ms
4001	3268ms

## Knapsack problem



U najgorem slučaju, naivno rekurzivno rješenje je u  $\Theta(2^n)$ . Ovo proističe iz toga što se pretražuje svaki podskup stavki kako bi se našao onaj koji maksimizira vrijednost bez prevazilaženja kapaciteta težine.

Rješenje zasnovano na dinamičkom programiranju ima pseudopolinomijalnu vremensku kompleksnost,  $\Theta(nC)$ , gdje je  $n$  broj stavki, a  $C$  kapacitet ranca. Poboljšana efikasnost proizilazi iz toga što je izbjegnuto ponovno izračunavanje potproblema, što je nedostatak naivnog pristupa.

Zadatak za vježbu. Modifikovati implementirani optimizovani algoritam, tako da, pored maksimalne ostvarive vrijednosti, vraća i koeficijente uključenja objekata  $c_1, c_2, \dots, c_n$ .

## Gradijentni spust

Zadatak. Dobijena su sljedeća mjerena t za ulaze n i m.

n	m	t
100	100	600000
100	200	1700000
200	100	1100000

Data je familija matematičkih modela za  $t$ ,

$$f(n, m) = K_1 n^2 + K_2 nm + K_3 m^2.$$

Pomoću tehnike gradijentnog spusta odrediti parametre  $K_1$ ,  $K_2$  i  $K_3$  i time odabratи adekvatan model iz navedene familije.

Ovo ćemo posmatrati ovo kao optimizacioni problem minimizacije greške matematičkog modela u odnosu na stvarna mjerena. Potrebno je prvo odabratи adekvatnu funkciju greške (gubitka - loss). Neka je  $C = 3$  broj mjerena. Možemo koristiti srednjekvadratnu grešku (mean squared error, MSE):

$$L(K_1, K_2, K_3) = \frac{1}{C} \sum_{i=1}^C (f(n_i, m_i) - t_i)^2$$

$$\frac{\partial L(K_1, K_2, K_3)}{\partial K_j} = \frac{1}{C} \sum_{i=1}^C \frac{\partial ((f(n_i, m_i) - t_i)^2)}{\partial K_j} = \frac{1}{C} \sum_{i=1}^C \frac{\partial ((f(n_i, m_i) - t_i)^2)}{\partial f(n_i, m_i)} \frac{\partial f(n_i, m_i)}{\partial K_j}$$

$$= \frac{2}{C} \sum_{i=1}^C (f(n_i, m_i) - t_i) \frac{\partial f(n_i, m_i)}{\partial K_j}$$

$$\frac{\partial L}{\partial K_1} = \frac{2}{C} \sum_{i=1}^C (f(n_i, m_i) - t_i) n_i^2$$

$$\frac{\partial L}{\partial K_2} = \frac{2}{C} \sum_{i=1}^C (f(n_i, m_i) - t_i) n_i m_i$$

$$\frac{\partial L}{\partial K_3} = \frac{2}{C} \sum_{i=1}^C (f(n_i, m_i) - t_i) m_i^2$$

```
In [24]: import numpy as np

# Data points
n = np.array([    100,      100,      200])
m = np.array([    100,      200,      100])
t = np.array([6000000, 17000000, 11000000])

# Initialize coefficients
Ks = np.array([1.0, 1.0, 1.0])

step_size = 5e-10 # TODO Need small value due to large magnitudes in the data. Pick
num_iterations = 10000

def f(n, m):
    return Ks[0] * n**2 + Ks[1] * n * m + Ks[2] * m**2

# Gradient descent loop
for i in range(num_iterations):
    # Compute current predictions
    errors = f(n, m) - t

    # Compute gradients
```

```

grad_K1 = (2/len(n)) * np.sum(errors * (n**2))
grad_K2 = (2/len(n)) * np.sum(errors * (n * m))
grad_K3 = (2/len(n)) * np.sum(errors * (m**2))
grad_Ks = np.array([grad_K1, grad_K2, grad_K3])

# Update the parameters
Ks = Ks - step_size * grad_Ks

# Print progress
if i % 1000 == 0:
    loss = np.mean((f(n, m) - t)**2) # Mean Squared Error
    print(f"Iteration {i}: Loss = {loss:.2f}, K1 = {Ks[0]:.4f}, K2 = {Ks[1]:.4f}
          K3 = {Ks[2]:.4f}")

print("\nFinal coefficients:")
print(f"K1 = {Ks[0]}")
print(f"K2 = {Ks[1]}")
print(f"K3 = {Ks[2]}")

```

```

Iteration 0: Loss = 80434703703.70, K1 = 22.0667, K2 = 20.6333, K3 = 28.0667
Iteration 1000: Loss = 1333274.76, K1 = 10.4238, K2 = 18.9609, K3 = 30.4238
Iteration 2000: Loss = 208773.78, K1 = 10.1677, K2 = 19.5888, K3 = 30.1677
Iteration 3000: Loss = 32691.30, K1 = 10.0664, K2 = 19.8373, K3 = 30.0664
Iteration 4000: Loss = 5119.04, K1 = 10.0263, K2 = 19.9356, K3 = 30.0263
Iteration 5000: Loss = 801.58, K1 = 10.0104, K2 = 19.9745, K3 = 30.0104
Iteration 6000: Loss = 125.52, K1 = 10.0041, K2 = 19.9899, K3 = 30.0041
Iteration 7000: Loss = 19.65, K1 = 10.0016, K2 = 19.9960, K3 = 30.0016
Iteration 8000: Loss = 3.08, K1 = 10.0006, K2 = 19.9984, K3 = 30.0006
Iteration 9000: Loss = 0.48, K1 = 10.0003, K2 = 19.9994, K3 = 30.0003

```

```

Final coefficients:
K1 = 10.000100908736716
K2 = 19.999752569935936
K3 = 30.000100908736716

```

Zadatak za vježbu. Modifikovati prethodni kod tako da se automatski probaju različite vrijednosti sa `step_size` sa fiksnim brojem iteracija, te da se odabere onaj `step_size` s kojim se pronađe najbolji rezultat.