

Formalne metode u softverskom inženjerstvu

06 Regularni jezici

ETFB 24-25

Dunja Vrbaški

Teorija formalnih jezika i automata

- Definisali smo formalni jezik: podskup reči nad nekim alfabetom
- Definisali smo konačne automate
(ekvivalencija eNKA, NKA, DKA; minimizacija, zatvorenost)
- Koja je veza između konačnih automata i nekih jezika?
- Kakvi jezici odgovaraju konačnim automatima?
- Šta znači "odgovaraju"?
- Kakvi još jezici postoje?
- Kakvi automati još postoje?
- Kakve to veze ima sa računarima i programiranjem?


Kako izgleda automat koji prepozna palindrom?

Konačni automati prihvataju **regularne** jezike.

- jezik u kom sve reči imaju neparan broj jedinica
 - imamo DKA
 - regularan jezik
- jezik u kom su svi palindromi
 - ne može se konstruisati DKA
 - nije regularan jezik


Regularni izrazi

- Regularni izrazi služe za definisanje jezika, za opis reči
- Ispostavlja se da upravo definišu regularne jezike
- RE ↔ DKA
- DKA **prepoznaje** jezik, prihvata ili ne prihvata reči
- RE su deklarativan način za opis jezika, mehanizam za **građenje** reči



$a(bba|bb)^*b$

regularni izraz



Regularni izrazi i jezici koje ovi izrazi definišu nad nekim alfabetom Σ se definišu rekurzivno:

- \emptyset je regularni izraz i označava jezik $L(\emptyset) = \{\}$,
- ϵ je regularni izraz i označava jezik $L(\epsilon) = \{\epsilon\}$,
- za svaki simbol $a \in \Sigma$, a je regularni izraz i označava jezik $L(a) = \{a\}$,
- ako su r i s regularni izrazi koji označavaju jezike $L(r)$ i $L(s)$, onda važe sledeće definicije:
 - $r \mid s$ je regularni izraz koji označava jezik $L(r \mid s) = L(r) \cup L(s)$
(često se koristi i operator +)
 - rs je regularni izraz koji označava jezik $L(rs) = L(r)L(s)$
 - r^* je regularni izraz koji označava jezik $L(r^*) = L(r)^*$

Regularni izrazi i jezici koje ovi izrazi definišu nad nekim alfabetom Σ se definišu rekurzivno:

- \emptyset je regularni izraz i označava jezik $L(\emptyset) = \{\}$,
- ϵ je regularni izraz i označava jezik $L(\epsilon) = \{\epsilon\}$,
- za svaki simbol $a \in \Sigma$, a je regularni izraz i označava jezik $L(a) = \{a\}$,
- ako su r i s regularni izrazi koji označavaju jezike $L(r)$ i $L(s)$, onda važe sledeće definicije:
 - $r \mid s$ je regularni izraz koji označava jezik $L(r \mid s) = L(r) \cup L(s)$ (često se koristi i operator $+$) alternative
 - rs je regularni izraz koji označava jezik $L(rs) = L(r)L(s)$ spajanje
 - r^* je regularni izraz koji označava jezik $L(r^*) = L(r)^*$ ponavljanje

Primer: $a(bba \mid bb)^*b$

- unarni operator * je levo asocijativan i ima najveći prioritet
 $r * s * t = (r * s) * t$
- operator konkatenacije je levo asocijativan i ima veći prioritet od operatora |
- operator | je levo asocijativan i ima najmanji prioritet

$01^*|1$ $0 \ 1^* \quad | \quad 1$

$(01)^*|1$ $(01)^* \quad | \quad 1$

$a|bc^*d$ $a \quad | \quad b \ c^* \ d$

$$L(a|b) = \{a, b\}$$

$$L((a|b)(a|b)) = \{aa, ab, ba, bb\}$$

$$L(a^*) = \{\varepsilon, a, aa, aaa, aaaa, \dots\}$$

$$L(a^*b^*) = \{\varepsilon, a, b, ab, aab, abbbb, aaaaa, \dots\}$$

$$L((a|b)^*) = \{\varepsilon, a, b, ab, ba, aabb, bbaa, \dots\}$$

$L((a|b)a(a|b))$ - jezik čije reči sadrže bar jedan simbol a

$L(a(a|b)^*b)$ - jezik čije reči počinju simbolom a i završavaju simbolom b

Zadatak: Napisati regularan izraz koji definiše jezik čije su reči sačinjene od naizmeničnog pojavljivanja 0 i 1

$$\{\varepsilon, \quad 0, 1, \quad 10, 01, \quad 101, 010, \quad 1010, 0101, \quad 10101, 01010, \dots\}$$

$$r \mid s = s \mid r$$

$$r \mid \emptyset = r = \emptyset \mid r$$

$$r \mid r = r$$

$$(r \mid s) \mid t = r \mid (s \mid t)$$


$$r\varepsilon = \varepsilon r = r$$

$$r\emptyset = \emptyset r = \emptyset$$


$$(rs)t = r(st)$$

$$r(s \mid t) = rs \mid rt$$

$$(r \mid s)t = rt \mid st$$



a(bba | bb)*b



a(ba)* (b | bab)*

Formalno, za regularne izraze definišemo samo tri operacije: |, · i *

Postoje proširenja radi jednostavnijeg zapisa koja se koriste u različitim bibliotekama i alatima.

Neki zapisi imaju svoju ekvivalentnu formu

$$R^+ = RR^*$$

POSIX (IEEE) standard: BRE (Basic) i ERE (Extended)

Obratiti pažnju prilikom korišćenja biblioteke

<code>^[\s]*(.*?)[\s]*\$</code>	trim whitespace (početak i kraj)
<code><([a-z]+)([^<]+)*(?:>(.*)<\/\1> \s+\/>)</code>	HTML element
<code>\B#(?:[a-fA-F0-9]{6} [a-fA-F0-9]{3})\b</code>	# boja heksadecimalno
<code>\b[\w.#!\$%&'*+/=?^`{ }~\-\]+@[\\w\-\]+\.(\\w\-\+)*\b</code>	email dovoljno dobro?

Oznaka	Primer	Formiranje	Skup reči
		Prazan string	
	a	Svaki simbol (karakter) je RE	
	ab	Vrši se konkatenacija dva RE	"ab"
*	ab*	RE na koji se odnosi se ponavlja 0 ili više puta	"a", "ab", "abb",....
+	ab+	RE na koji se odnosi se ponavlja 1 ili više puta	"ab", "abb",....
?	ab?	RE na koji se odnosi se ponavlja 0 ili 1 put	"a", "ab"

Oznaka	Primer	Formiranje	Skup reči
	a b	Alternativa	“a”, “b”
()	a(b c)	Grupisanje	“ab”, “ac”
[]	[abc]	Alternative	“a”, “b”, “c”
[-]	[a-c]	Opseg	“a”, “b”, “c”
[^]	[^abc]	Alternative koje ne odgovaraju navedenim	“d”, “e”,....(ostalo iz azbuke)
{m, n}	a{1, 3}	Broj ponavljanja	“a”, “aa”, “aaa”
.	a.	Bilo koji znak (osim nove linije) [a.b] – tu se često interpretira baš kao znak “.”	“aa”, “ab”, “ac”...
\	a\.	Escape, specijalne karaktere tretiramo kao obične	“a.”

```
String[] tekst = { "Marko Markovic +387(65)000-000", "Janko Jankovic +387(51)111-111",
    "Jovan Jovanovic +387(51)222-222", "Nenad Nenadovic +387(65)333-333",
    "Marko Jankovic +387(65)444-444", "ABC", "AABBCCC dodatni tekst", "AAABBBCC", "tekst123",
    "office@etf.unibl.org", "nevalidan@etf.tv" };

String[] regularniIzrazi = { "tekst", "tekst$", ".+[A-Za-z]{3}ko", "^[A-Za-z]{2}ko ", "[A-Za-z]{3}ko ",
    "(Jan)+", "(Jan.{3}){2}", "\\+387\\(51\\)[0-9]{3}-[0-9]{3}",
    "[a-z]{1}[a-z0-9]*@[a-z0-9]+\.\+[a-z]{3}$" };

for (String regex : regularniIzrazi) {
    Pattern pattern = Pattern.compile(regex);
    for (String ulaz : tekst) {
        Matcher matcher = pattern.matcher(ulaz);
        if (matcher.find())
            System.out.println("Izraz " + regex + " prihvata sekvencu: " + matcher.group() + " u ulazu " + ulaz);
        System.out.println();
    }
}
```

java

```

string pattern = "(Mr\\\\.? |Mrs\\\\.? |Miss |Ms\\\\.? )";
string[] names = { "Mr. Henry Hunt", "Ms. Sara Samuels",
                  "Abraham Adams", "Ms. Nicole Norris" };

foreach (string name in names)
    Console.WriteLine(Regex.Replace(name, pattern, String.Empty));

// 

Regex rx = new Regex(@"\b(?<word>\w+)\s+(\k<word>)\b",
    RegexOptions.Compiled | RegexOptions.IgnoreCase);

// Define a test string.
string text = "The the quick brown fox  fox jumps over the lazy dog dog.";

// Find matches.
MatchCollection matches = rx.Matches(text);

// Report the number of matches found.
Console.WriteLine("{0} matches found in:\n  {1}",
                 matches.Count,
                 text);

// Report on each match.
foreach (Match match in matches)
{
    GroupCollection groups = match.Groups;
    Console.WriteLine("'{0}' repeated at positions {1} and {2}",
                     groups["word"].Value,
                     groups[0].Index,
                     groups[1].Index);
}

```

C#

```
#!/bin/bash

echo ispisuje sve redove koji sadrze rijec \"tekst\
grep --color -E "tekst" tekst.txt
echo -e "\n"

echo ispisuje sve redove kod kojih se rijec \"tekst\" nalazi na kraju reda
grep --color -E "tekst$" tekst.txt
echo -e "\n"

echo ispisuje sve redove koji sadrze fiksni broj telefona iz Banjaluke u formatu
+387\((51\)xxx-xxx
grep --color -E "\+387\((51\[0-9]{3}-[0-9]{3}" tekst.txt
echo -e "\n"
```


Linux, grep
Globally search a Regular Expression and Print

Kako biste vi implementirali?


RE → regularni jezici

regularni jezici → konačni automati

Da li postoji sistematičan način da od proizvoljnog regularnog izraza kreiramo konačni automat?



$a(bba|bb)^*b$



$a(ba)^*((b|bab)^*b)$


Konstrukcija automata za RE

- \emptyset je regularni izraz i označava jezik $L(\emptyset) = \{\}$,
- ϵ je regularni izraz i označava jezik $L(\epsilon) = \{\epsilon\}$,
- za svaki simbol $a \in \Sigma$, a je regularni izraz i označava jezik $L(a) = \{a\}$,
- ako su r i s regularni izrazi koji označavaju jezike $L(r)$ i $L(s)$, onda važe sledeće definicije:
 - $r | s$ je regularni izraz koji označava jezik $L(r | s) = L(r) \cup L(s)$
(često se koristi i operator +)
 - rs je regularni izraz koji označava jezik $L(rs) = L(r)L(s)$
 - r^* je regularni izraz koji označava jezik $L(r^*) = L(r)^*$

\emptyset

$$L(\emptyset) = \emptyset$$

$$A = (\{q_0, q_1\}, \Sigma, \sigma, s_0, \{q_1\})$$




Nema prelaska
Ni za ϵ

Ne prihvata nijednu reč.

ε

$$L(\varepsilon) = \{\varepsilon\}$$


$$A = (\{q_0, q_1\}, \Sigma, \sigma, s_0, \{q_1\})$$



$a \in \Sigma$

$L(a) = \{a\}$

$A = (\{q_0, q_1\}, \Sigma, \sigma, s_0, \{q_1\})$



$$r_1 | r_2$$
$$L(r_1 | r_2) = L(r_1) \cup L(r_2)$$

$$r_1: A_1 = (S_1, \Sigma_1, \sigma_1, s_1, F_1), \quad r_2: A_2 = (S_2, \Sigma_2, \sigma_2, s_2, F_2)$$

Automati dobijeni prethodnim koracima.
Imaju samo jedno završno stanje iz kojih nema prelaza.

$$F_1 = \{f_1\}, \quad F_2 = \{f_2\}$$

$$A = (S_1 \cup S_2 \cup \{s_0, f\}, \Sigma_1 \cup \Sigma_2, \sigma, s_0, F)$$

s_0 - novo početno stanje

$F = \{f\}$ - novo završno stanje iz kog nema prelaza

$\sigma = ?$

$$r_1 | r_2$$

$$L(r_1 | r_2) = L(r_1) \cup L(r_2)$$

$$r_1: A_1 = (S_1, \Sigma_1, \sigma_1, s_1, F_1), \quad r_2: A_2 = (S_2, \Sigma_2, \sigma_2, s_2, F_2)$$

Automati dobijeni prethodnim koracima.

Imaju samo jedno završno stanje iz kojih nema prelaza.


$$F_1 = \{f_1\}, \quad F_2 = \{f_2\}$$

$$A = (S_1 \cup S_2 \cup \{s_0, f\}, \Sigma_1 \cup \Sigma_2, \sigma, s_0, F)$$

s_0 - novo početno stanje

$F = \{f\}$ - novo završno stanje iz kog nema prelaza

$$\sigma = ?$$



Na slici je oznaka za stanje q , u definiciji s

$$r_1: A_1 = (S_1, \Sigma_1, \sigma_1, s_1, F_1), \quad r_2: A_2 = (S_2, \Sigma_2, \sigma_2, s_2, F_2)$$

$$A = (S_1 \cup S_2 \cup \{s_0, f\}, \Sigma_1 \cup \Sigma_2, \sigma, s_0, F)$$

s_0 - novo početno stanje

$F = \{f\}$ - novo završno stanje iz kog nema prelaza


$\sigma = ?$

$$\sigma(s_0, \varepsilon) = \{s1, s2\}$$

$$\begin{aligned} \sigma(s, a) &= \sigma_1(s, a), \quad a \in \Sigma_1 \text{ i } s \in S_1 \setminus \{f_1\} \\ &= \sigma_2(s, a), \quad a \in \Sigma_2 \text{ i } s \in S_2 \setminus \{f_2\} \end{aligned}$$

$$\sigma(f_1, \varepsilon) = \{f\}$$

$$\sigma(f_2, \varepsilon) = \{f\}$$



Na slici je oznaka za stanje q , u definiciji s


$$r_1 | r_2$$
$$L(r_1 | r_2) = L(r_1) \cup L(r_2)$$

Iz početnog prelazi u početna stanja A_1 i A_2

Ponaša se isto kao A_1 ili A_2 , zavisno od stanja

Iz završnih stanja A_1 i A_2 prelazi u novo završno

obezbeđujemo preduslov da automat ima jedno završno stanje, bez prelaza



Na slici je oznaka za stanje q , u definiciji s

$$\begin{aligned} \textcolor{blue}{r_1 \cdot r_2} \\ L(r_1 \cdot r_2) = L(r_1) \cup L(r_2) \end{aligned}$$

$$r_1: A_1 = (S_1, \Sigma_1, \sigma_1, s_1, F_1), \quad r_2: A_2 = (S_2, \Sigma_2, \sigma_2, s_2, F_2)$$


Automati dobijeni prethodnim koracima.
Imaju samo jedno završno stanje iz kojih nema prelaza.

$$F_1 = \{f_1\}, \quad F_2 = \{f_2\}$$

$$A = (S_1 \cup S_2, \Sigma_1 \cup \Sigma_2, \sigma, s_1, F)$$

$$F = \{f_2\} - f_2 \text{ nema prelaza}$$

$$\sigma = ?$$




$$\begin{matrix} \textcolor{blue}{r_1 \cdot r_2} \\ L(r_1 \cdot r_2) = L(r_1) L(r_2) \end{matrix}$$

Počinje kako počinje A_1

Završava se gde se završava A_2

Ponaša se isto kao A_1 ili A_2 , zavisno od stanja



$$\begin{array}{c} r_1^* \\ L(r_1^*) = L(r_1)^* \end{array}$$

$$r_1 : A_1 = (S_1, \Sigma_1, \sigma_1, s_1, F_1)$$

Automati dobijeni prethodnim koracima.
Imaju samo jedno završno stanje iz kojih nema prelaza.


$$F_1 = \{f_1\}$$

$$A = (S_1 \cup \{s_0, f\}, \Sigma_1, \sigma, s_0, F)$$

s_0 - novo početno stanje

$F = \{f\}$ - novo završno stanje

$$\sigma = ?$$




$$L(r_1^*) = L(r_1)^*$$

Omogućava praznu reč
(broj ponavljanja = 0)

Ponaša se isto kao A_1

Omogućava ponavljanje
(iz završnog A_1 se vrati na početak ili završi)



PRIMER: $r = b(ab)^* | ab^*a$

$$r = b(ab)^* \mid ab^*a$$

$$r = r_1 \mid r_2$$

$$r_1 = b(ab)^*$$

$$r_2 = ab^*a$$

$$r_1 = r_3 r_4$$

$$r_3 = b$$

$$r_4 = (ab)^*$$

$$r_4 = r_5^*$$

$$r_5 = ab$$

$$r_5 = r_6 r_7$$

$$r_6 = a$$

$$r_7 = b$$

$$r_2 = r_8 r_9$$

$$r_8 = a$$

$$r_9 = b^*a$$







$$r_9 = r_{10} r_{11}$$

$$r_{10} = b^*$$

$$r_{11} = a$$

$$r_{10} = r_{12}^*$$

$$r_{12} = b$$



$$r = b(ab)^* \mid ab^*a$$

$$\begin{aligned} r &= r_1 \mid r_2 \\ r_1 &= b(ab)^* \\ r_2 &= ab^*a \end{aligned}$$

$$\begin{aligned} r_1 &= r_3 r_4 \\ r_3 &= b \\ r_4 &= (ab)^* \end{aligned}$$



$$\begin{aligned} r_4 &= r_5^* \\ r_5 &= ab \end{aligned}$$

$$\begin{aligned} r_5 &= r_6 r_7 \\ r_6 &= a \\ r_7 &= b \end{aligned}$$

$$\begin{aligned} r_2 &= r_8 r_9 \\ r_8 &= a \\ r_9 &= b^*a \end{aligned}$$

$$\begin{aligned} r_9 &= r_{10} r_{11} \\ r_{10} &= b^* \\ r_{11} &= a \end{aligned}$$

$$\begin{aligned} r_{10} &= r_{12}^* \\ r_{12} &= b \end{aligned}$$



$$r = b(ab)^* \mid ab^*a$$

$$\begin{aligned} r &= r_1 \mid r_2 \\ r_1 &= b(ab)^* \\ r_2 &= ab^*a \end{aligned}$$

$$\begin{aligned} r_1 &= r_3 r_4 \\ r_3 &= b \\ r_4 &= (ab)^* \end{aligned}$$


$$\begin{aligned} r_4 &= r_5^* \\ r_5 &= ab \end{aligned}$$

$$\begin{aligned} r_5 &= r_6 r_7 \\ r_6 &= a \\ r_7 &= b \end{aligned}$$

$$\begin{aligned} r_2 &= r_8 r_9 \\ r_8 &= a \\ r_9 &= b^*a \end{aligned}$$

$$\begin{aligned} r_9 &= r_{10} r_{11} \\ r_{10} &= b^* \\ r_{11} &= a \end{aligned}$$

$$\begin{aligned} r_{10} &= r_{12}^* \\ r_{12} &= b \end{aligned}$$



RE → e-NKA → NKA → DKA

RE ← e-NKA ← NKA ← DKA ??